

Segmentación de clientes en una plataforma de comercio electrónico

Análisis no supervisado sobre datos de Google Analytics

Andrés Fernando Gómez Rojas

3 de junio de 2026

Resumen

Se aborda el problema de segmentar visitantes de un sitio de comercio electrónico a partir de datos de comportamiento de Google Analytics, con el objetivo de proveer al equipo de marketing grupos accionables para personalizar campañas y optimizar inversión. A partir de un dataset de 9.996 visitantes únicos pre-agregados, se aplica un pipeline que parte de un análisis exploratorio riguroso, atraviesa una etapa de feature engineering justificada en hallazgos concretos del exploratorio, compara seis algoritmos de clustering y termina con una validación estadística formal de los segmentos obtenidos. La solución final emplea KMeans con cuatro clusters, elegida por el balance entre métricas internas, estabilidad bajo bootstrap y accionabilidad de los segmentos para marketing. Los cuatro grupos identificados (Desktop Engaged, Desktop Frecuente, Weekend Warriors y Mobile Users) muestran diferencias estadísticamente significativas y, lo que es más relevante, con effect size grande. El análisis revela además que el dispositivo es el separador dominante por encima del canal de adquisición, contradiciendo un supuesto habitual en marketing digital.

1. Introducción

Para una empresa de comercio electrónico, entender a sus visitantes en grupos diferenciados es un insumo directo para la toma de decisiones de marketing. Permite personalizar campañas, distribuir presupuesto entre canales con criterio y diseñar experiencias adaptadas al tipo de usuario. Este informe documenta el ejercicio de segmentar los visitantes de un sitio web a partir de información de comportamiento extraída de Google Analytics, sin variables de conversión ni de revenue, por lo que el objetivo es descriptivo y operativo más que predictivo.

El dataset entregado contiene 9.996 filas y trece variables que mezclan identificadores, métricas de actividad y atributos de dispositivo y canal. Una observación temprana define todo el enfoque del trabajo: cada fila corresponde a un visitante único, no a una sesión. La columna llamada `sessionId` no es un identificador sino el número de sesiones que realizó cada visitante, con rango entre uno y doscientas setenta y ocho. Las variables `weekend_prop`, `bounce_prop` y `device.isMobile` son proporciones agregadas a través de las sesiones del visitante. Reconocer esto temprano evita malinterpretar los datos y permite abordar el problema directamente como una segmentación a nivel persona, sin necesidad de agregar antes.

2. Análisis exploratorio

El análisis exploratorio cumple en este trabajo dos propósitos. Por una parte, verificar la calidad de los datos y caracterizar las variables. Por otra, producir hallazgos que justifiquen las decisiones de preprocesamiento que vienen después. Toda transformación posterior debe rastrearse a una observación concreta del exploratorio.

La calidad del dataset es notablemente buena. No hay valores nulos en ninguna de las columnas, no hay duplicados completos, y todas las restricciones lógicas se cumplen: las proporciones están entre cero y uno, las horas entre cero y veintitrés, los pageviews nunca exceden los hits, y cada visitante aparece una sola vez. Solo cuatro visitantes presentan valores intermedios en

`device.isMobile`, lo que indica que cambiaron de dispositivo entre sesiones. La composición del dataset sugiere fuertemente que se trata de la muestra de Google Merchandise Store usada históricamente para tutoriales de Google Analytics: noventa por ciento de visitantes en desktop, ochenta y nueve por ciento usando Chrome, cincuenta y seis por ciento en Macintosh. Reconocer este sesgo del origen es relevante para interpretar después la representatividad de los segmentos mobile.

Las distribuciones de las variables de conteo son extremadamente sesgadas a la derecha. La skewness de `n_sessions` supera los diecinueve y su kurtosis se acerca a seiscientos sesenta, lo que confirma una cola pesadísima dominada por unos pocos visitantes con cientos de sesiones. Las variables `totals.hits` y `totals.pageviews` presentan también skewness por encima de cinco. Esto tiene dos implicaciones técnicas. Primero, ninguna prueba paramétrica que asuma normalidad será apropiada para estas variables, por lo que descartamos ANOVA en favor de Kruskal-Wallis, y Pearson en favor de Spearman. Segundo, antes de aplicar cualquier algoritmo basado en distancia euclidiana es necesario transformar estas variables para que un puñado de outliers no dominen las distancias.

El análisis bivariado revela dos redundancias importantes. La primera, entre `totals.hits` y `totals.pageviews`, con correlación de Spearman de 0.97 y factor de inflación de varianza por encima de veintisiete. La segunda, entre `channelGrouping` y `trafficSource.medium`, con un V de Cramer de 0.98, prácticamente la misma variable expresada en dos formas. Estas redundancias se atienden en el preprocesamiento eliminando una de las dos variables del segundo par y derivando una métrica complementaria del primero.

Un hallazgo del exploratorio que merece destacarse, porque anticipa la estructura del clustering posterior, es la correlación negativa de Spearman entre `n_sessions` y `totals.hits`, con valor de -0.64. Quien viene más veces tiene menos hits totales que quien viene pocas veces. La interpretación que damos es que coexisten dos comportamientos opuestos en la base de visitantes: personas que vienen una o dos veces y realizan sesiones extensas de investigación, y personas que vienen muchas veces pero hacen sesiones cortas de chequeo rápido. Esta dualidad se va a recuperar después como dos clusters distintos.

Para cerrar el exploratorio se aplicó Isolation Forest sobre las variables numéricas con un nivel de contaminación del cinco por ciento, lo que identifica visitantes con combinaciones inusuales de comportamiento que no necesariamente son outliers en una variable aislada. Los outliers multivariados resultan ser visitantes con engagement aproximadamente cinco veces superior al típico, y el separador más fuerte entre outliers y resto es `weekend_prop`. Esto anticipa, antes siquiera de hacer clustering, la existencia de un segmento de visitantes muy activos en fin de semana. La decisión sobre estos outliers es no eliminarlos: son precisamente los power users que el negocio querría identificar. En cambio, se tratan con clip al percentil 99 y transformación logarítmica antes del clustering.

3. Preprocesamiento

Todas las decisiones de preprocesamiento se derivan de observaciones del análisis exploratorio. No hay transformaciones aplicadas por inercia.

Las variables de conteo `n_sessions`, `totals.hits` y `totals.pageviews`, junto con sus derivadas `hits_per_session` y `pageviews_per_session`, se truncan al percentil 99 y luego se aplica `log1p`. El clip evita que cinco o seis outliers extremos definan la escala completa de la variable. El logaritmo comprime la cola derecha y deja distribuciones aproximadamente simétricas que el `StandardScaler` posterior puede escalar de manera sensata. Tras la transformación, la skewness de estas variables baja de valores por encima de cinco a magnitudes cercanas a cero.

Se construyen tres features nuevas. La métrica `hits_per_session` distingue la intensidad por visita de la cantidad total de actividad acumulada por el visitante: dos personas pueden tener treinta hits totales, pero significan cosas muy distintas si uno los hizo en una sola sesión y otro repartidos en diez. Análogamente `pageviews_per_session`. La métrica `hits_per_pageview` sirve como proxy de interacción más allá de la navegación pura, capturando clicks de producto, eventos y otras interacciones que no incrementan el contador de pageviews. Finalmente `part_of_day` discretiza la hora en cuatro bloques, ya que la hora cruda resultó tener poco poder de separación.

Las variables categóricas con cola larga se reagrupan. En navegadores se conservan Chrome, Safari y Firefox; el resto se colapsa en una categoría Other. En sistema operativo se conservan Macintosh, Windows, iOS y Android. Sin esta agrupación, el one-hot generaría columnas con cinco o diez observaciones cada una, que solo añaden ruido al cálculo de distancias.

Se elimina `trafficSource.medium` por la redundancia perfecta con `channelGrouping` ya descrita. La matriz final combina ocho variables numéricas escaladas con `StandardScaler` y veinticuatro columnas resultantes del one-hot de cinco variables categóricas, produciendo un espacio de treinta y dos dimensiones sobre nueve mil novecientas noventa y seis observaciones.

4. Metodología de segmentación

La elección de algoritmo y número de clusters se sustenta en tres criterios combinados: métricas internas estándar, estabilidad bajo perturbaciones y accionabilidad de los segmentos resultantes para el negocio.

Para seleccionar el número de clusters se evaluó KMeans con valores de K entre dos y ocho, utilizando cuatro métricas: silhouette, índice de Calinski-Harabasz, índice de Davies-Bouldin y la inercia para detectar el codo. La figura ?? muestra el comportamiento de cada métrica.




Figura 1: Métricas internas para distintos valores de K. La línea roja marca el valor elegido. K=3 y K=4 muestran métricas muy similares; el desempate se hace por accionabilidad.

Las métricas son ligeramente mejores en K=3 (silhouette de 0.26 contra 0.25, Davies-Bouldin de 1.38 contra 1.42), pero con K=3 el cluster de visitantes mobile queda diluido dentro del segmento de desktop superficiales. Con K=4 el segmento mobile emerge como entidad propia, lo cual abre una palanca de marketing concreta. La diferencia en métricas es marginal y la ganancia operativa es sustantiva, así que se elige K=4. Este es exactamente el tipo de decisión donde el criterio cuantitativo se complementa con el criterio de negocio sin pretender que uno reemplace al otro.

Para confirmar que la elección no es un artefacto del algoritmo, se compararon tres familias distintas de clustering aplicadas con K=4: KMeans, clustering aglomerativo con linkage de Ward y Gaussian Mixture Model con covarianza completa. KMeans y Ward producen soluciones muy parecidas con silhouette de 0.25 y 0.23 respectivamente; el GMM produce una solución diferente con peor separación geométrica. La concordancia entre KMeans y Ward es una señal fuerte de que la estructura encontrada no es producto de un algoritmo particular, sino que refleja patrones reales en los datos. Adicionalmente se exploró HDBSCAN, cuyo resultado revela algo interesante:

con cualquier parámetro razonable encuentra solamente dos clusters densos, mobile y todo lo demás. Esto se interpreta como que el cluster mobile es genuinamente denso en el sentido de densidad espacial, mientras que los otros tres segmentos son particiones funcionales sobre un continuo de engagement. Esta honestidad analítica vale la pena explicitarla: los segmentos C0, C1 y C2 son cortes operativos útiles sobre una nube continua, no agrupaciones naturalmente discretas.

Se eligió KMeans por encima de Ward por una razón operativa: los centroides permiten asignar visitantes nuevos en producción con una sola operación de distancia mínima, sin necesidad de recomputar el árbol jerárquico ni almacenar matrices de covarianza. Este es un punto importante: la elección no solo favorece la calidad estadística sino también la viabilidad de despliegue.

5. Validación de robustez y tests estadísticos

Una segmentación obtenida con un algoritmo no supervisado no tiene etiquetas verdaderas contra qué comparar. No existe accuracy ni área bajo la curva. La validación entonces se enfoca en una pregunta distinta: ¿son los clusters encontrados estables y reproducibles, o son un artefacto de la muestra específica? Esta pregunta se aborda con tres tipos de pruebas complementarias.

La primera es estabilidad por bootstrap. Se reentrenan treinta modelos KMeans con muestras del ochenta por ciento del dataset, se asignan los visitantes completos usando los centroides de cada bootstrap, y se compara cada asignación con la del modelo base usando el Adjusted Rand Index. El ARI mide acuerdo entre dos particiones corrigiendo por azar, vale uno cuando son idénticas y cero cuando son tan parecidas como dos asignaciones aleatorias. El resultado del ejercicio es un ARI medio de 0.974 con mediana de 0.994. Los clusters reaparecen casi idénticos con datos distintos.

La segunda prueba es hold-out 80/20. Se entrenan los centroides con el ochenta por ciento de los datos, se asigna el veinte por ciento restante usando esos centroides, y se compara el silhouette en el conjunto de entrenamiento contra el de prueba. Si los clusters fueran un sobreajuste, el silhouette en prueba caería considerablemente. El resultado es un silhouette de 0.243 tanto en entrenamiento como en prueba, con una diferencia inferior a una milésima en promedio sobre diez folds. Los centroides aprendidos en una muestra generalizan a datos no vistos sin pérdida.

La tercera prueba es robustez al ruido. Se añade perturbación gaussiana con desviación estándar de 0.1 al dataset escalado y se predice de nuevo con los centroides originales. El ARI entre las asignaciones originales y las perturbadas se mantiene en 0.96, lo que significa que solo el cuatro por ciento de los visitantes cambian de cluster ante perturbaciones pequeñas.

Pasamos luego a la validación estadística formal sobre los clusters obtenidos. Antes de elegir test, verificamos normalidad con D'Agostino-Pearson dentro de cada cluster. Ninguna variable es normal en ningún cluster, lo cual lleva a descartar ANOVA en favor de Kruskal-Wallis. Es importante señalar que con un tamaño muestral cercano a diez mil, casi cualquier diferencia produce p-valores prácticamente cero. La interpretación se centra entonces en effect size, eta-cuadrado para Kruskal-Wallis y V de Cramer para chi-cuadrado, que es lo que distingue diferencias triviales de diferencias importantes.

La tabla ?? resume el effect size por variable.

Siete de ocho variables muestran effect size grande, lo que confirma que los clusters no son una partición arbitraria sino que capturan diferencias sustanciales en el comportamiento de los visitantes. La única excepción es **hour**, con effect size trivial. La hora del día no separa los clusters, y esto contradice un supuesto común en marketing digital de que el momento de la visita es un segmentador relevante.

Cuadro 1: Effect size de Kruskal-Wallis por variable numérica.

Variable	η^2	Magnitud
hits_per_session	0.645	grande
pageviews_per_session	0.638	grande
n_sessions	0.562	grande
totals.pageviews	0.539	grande
totals.hits	0.528	grande
weekend_prop	0.503	grande
bounce_prop	0.257	grande
hour	0.017	trivial

El post-hoc de Dunn con corrección de Bonferroni permite identificar qué pares específicos de clusters difieren. El resultado más interesante aparece en **hits_per_session**: los clusters C0 (Desktop Engaged) y C2 (Weekend Warriors) no se diferencian estadísticamente en intensidad de engagement por sesión. Su única diferencia significativa está en **weekend_prop**. Interpretado correctamente, esto significa que C2 no es un tipo de usuario distinto de C0; es el mismo tipo de usuario activo en un momento de la semana diferente. Esta clase de matiz no es visible mirando solo la salida del clustering y solo emerge al aplicar tests formales sobre los resultados.

Para las variables categóricas, el chi-cuadrado con V de Cramer produce el resultado más relevante para marketing: **device.deviceCategory** tiene V de 0.70, una asociación fuerte con la pertenencia a cluster, mientras que **channelGrouping** apenas alcanza V de 0.19, asociación débil. La lectura es clara: el dispositivo es el separador dominante, no el canal de adquisición. Esto vuelve a contradecir el supuesto frecuente de que el canal debe ser la dimensión central de cualquier segmentación de marketing.

Finalmente el MANOVA con Wilks' Lambda confirma a nivel multivariado que los centroides de los cuatro clusters difieren globalmente en el espacio conjunto de las variables numéricas, con $\Lambda = 0,62$ y p prácticamente cero. Es la confirmación final de que los grupos son entidades separadas en el espacio conjunto y no solo en variables individuales.

6. Resultados: los cuatro segmentos

La figura ?? muestra la proyección bidimensional de los visitantes en el espacio de componentes principales, coloreados por cluster. Las dos primeras componentes explican aproximadamente la mitad de la varianza, lo suficiente para que la separación entre grupos sea visualmente clara.

Cuadro 2: Perfil promedio de cada segmento.

Segmento	n	%	sesiones	hits/ses	bounce	weekend	mobile
C0 Desktop Engaged	4.247	42.5	1.65	25.21	0.01	0.01	0.00
C1 Desktop Frecuente	3.819	38.2	6.36	2.14	0.15	0.10	0.00
C2 Weekend Warriors	973	9.7	1.69	25.44	0.03	0.85	0.01
C3 Mobile Users	957	9.6	3.28	12.69	0.17	0.25	1.00

El segmento Desktop Engaged concentra al 42.5 por ciento de los visitantes y representa al usuario que visita pocas veces pero con sesiones largas y profundas. En promedio realizan 1.65 sesiones con veinticinco hits cada una. Su tasa de rebote es del uno por ciento, prácticamente nula. Llegan mayoritariamente por canales Direct y Organic Search, lo que sugiere usuarios con




Figura 2: Proyección PCA en dos dimensiones de los cuatro segmentos identificados.

intención de compra ya formada. Este es el segmento que efectivamente convierte y la prioridad para él no es la atracción sino la conversión: testing A/B sobre el checkout, mejora de páginas de producto, programas de fidelización para retener.

El segmento Desktop Frecuente es el más interesante desde el punto de vista estratégico. Agrupa al 38.2 por ciento de los visitantes y se caracteriza por un patrón aparentemente contradictorio: vienen muchas veces, en promedio seis sesiones, pero cada sesión es muy corta, con apenas dos hits. Bounce rate del quince por ciento. El cincuenta y cinco por ciento llegan por canal Referral, lo que apunta a lectores de blogs, comparadores o reviews que regresan al sitio en busca de información puntual. Esta es la audiencia con mayor potencial de crecimiento. La estrategia adecuada es nurturing con contenido educativo, emails con valor antes de cualquier promoción, retargeting con guías de producto en lugar de descuentos.

El segmento Weekend Warriors es pequeño pero homogéneo, con 973 visitantes que concentran el ochenta y cinco por ciento de sus visitas en sábado y domingo. Su engagement es equivalente al de Desktop Engaged en términos de hits por sesión y bounce rate. Como se discutió en la sección de tests estadísticos, el post-hoc confirma que son indistinguibles de Desktop Engaged en intensidad y solo se diferencian en el momento de la semana. La interpretación operativa es directa: son power users con disponibilidad de fin de semana. Las acciones recomendadas son campañas programadas con dayparting viernes a domingo, mayor inversión en paid search en esos días y contenido más visual y orientado al ocio.

El segmento Mobile Users agrupa al diez por ciento restante, todos en mobile o tablet, repartidos casi por mitades entre iOS y Android. Tienen engagement medio pero un bounce rate del diecisiete por ciento, diecisiete veces el de Desktop Engaged. La mayor proporción de Paid Search dentro de este cluster señala algo importante para el negocio: se está pagando para llevar tráfico mobile a una experiencia que no convierte. Antes de cualquier campaña adicional, la prioridad debe ser de producto y no de marketing: auditoría de Core Web Vitals, optimización del peso de

imágenes, revisión del flujo de checkout mobile. Mientras la experiencia no se arregle, incrementar la inversión de adquisición sobre este segmento es ineficiente.




Figura 3: Composición categórica por cluster: canal de adquisición, dispositivo y momento del día.

7. Recomendaciones de marketing

Las recomendaciones se derivan directamente de los perfiles y de los hallazgos estadísticos. Para Desktop Engaged el objetivo es maximizar conversión y ticket medio en una audiencia que ya está convencida, con foco en optimización de la experiencia de compra y programas de loyalty. Para Desktop Frecuente, donde está el mayor potencial de crecimiento, la estrategia es nurturing por contenido con métricas de éxito centradas en aumentar las páginas vistas por sesión y la profundidad del engagement, no en conversión inmediata. Para Weekend Warriors, el enfoque es captura en ventana de oportunidad, con campañas programadas y oferta de tiempo limitado en fines de semana. Para Mobile Users, la recomendación es atípica: antes de invertir en marketing hay que invertir en producto, porque el problema observado no es de adquisición sino de experiencia.

Una recomendación transversal que el análisis estadístico justifica es revisar la asignación de presupuesto entre canales. El dispositivo separa mucho más que el canal, por lo que campañas pensadas como “canal Referral” pueden estar subóptimamente diseñadas si dentro de ese canal coexisten usuarios desktop con intent profundo y usuarios mobile con intent superficial.

8. Limitaciones

El dataset no contiene variables de conversión, revenue o lifetime value, por lo que la segmentación captura comportamiento de engagement pero no valor de negocio. Una iteración natural sería complementar este trabajo con una segmentación por valor (modelo RFM o LTV) que requiere datos transaccionales. También sería valioso validar cualitativamente los segmentos con el equipo de marketing, revisando una muestra de treinta a cincuenta visitantes por cluster y verificando que los perfiles coinciden con lo que observan en el día a día. Por último, la composición del dataset apunta fuertemente a tratarse de la muestra del Google Merchandise Store, con su sesgo característico hacia Chrome y Macintosh; los segmentos mobile en particular están contruidos sobre una minoría del diez por ciento del dataset y conviene tomar sus conclusiones con cautela en consecuencia.

9. Conclusiones

El trabajo entrega una segmentación accionable en cuatro grupos diferenciados, con cada grupo respaldado por effect sizes grandes en variables clave y con la estabilidad confirmada bajo bootstrap y hold-out. Más allá del resultado, el ejercicio aporta dos hallazgos que un análisis menos riguroso podría pasar por alto. El primero, que dos de los cuatro segmentos (Desktop Engaged y Weekend Warriors) son funcionalmente equivalentes en su intensidad de engagement y solo se diferencian en el momento de la semana en que actúan; reconocerlo permite diseñar estrategias más eficientes que tratan al mismo usuario con el contenido adecuado para cada ventana de tiempo. El segundo, que el dispositivo es el separador dominante por encima del canal de adquisición, lo cual reorienta las prioridades de inversión: mejorar la experiencia mobile rinde más que aumentar el presupuesto de adquisición sobre una experiencia que no convierte.