

Desafio de Segmentacion de Clientes

Informe Tecnico Completo

Analisis Exploratorio, Preprocesamiento, Metodologia,
Validacion Estadistica, Resultados y Recomendaciones

Andres Fernando Gomez Rojas

Brain Food | Junio 2026

Tabla de Contenidos

1. Introduccion y contexto del problema
2. Analisis exploratorio de datos
 - 2.1 Diccionario de datos y tipologia
 - 2.2 Calidad de datos
 - 2.3 Analisis univariado numerico
 - 2.4 Deteccion de outliers univariados
 - 2.5 Analisis univariado categorico
 - 2.6 Correlaciones y multicolinealidad
 - 2.7 Analisis bivariado categorica-numerica
 - 2.8 Analisis bivariado categorica-categorica
 - 2.9 Outliers multivariados con Isolation Forest
 - 2.10 Sintesis del EDA
3. Preprocesamiento y feature engineering
 - 3.1 Variables derivadas
 - 3.2 Transformaciones aplicadas
 - 3.3 Agrupacion de categorias raras
 - 3.4 Variables eliminadas
 - 3.5 Matriz final
4. Metodologia de segmentacion
 - 4.1 Seleccion del numero de clusters
 - 4.2 Benchmark de algoritmos
 - 4.3 Justificacion de KMeans
5. Validacion de robustez
 - 5.1 Estabilidad multi-semilla
 - 5.2 Bootstrap stability
 - 5.3 Hold-out 80/20

5.4 Robustez al ruido

5.5 Estabilidad por cluster (Jaccard)

6. Validacion estadistica formal

6.1 Verificacion de supuestos

6.2 Kruskal-Wallis y effect size

6.3 Post-hoc de Dunn

6.4 Tests para categoricas

6.5 MANOVA multivariado

7. Resultados: perfilado de los cuatro segmentos

8. Recomendaciones de marketing

9. Limitaciones

10. Conclusiones y siguientes pasos

1. Introduccion y Contexto del Problema

En el contexto del comercio electronico actual, las empresas enfrentan un desafio creciente: atender a una base de usuarios cada vez mas diversa. Las metricas agregadas del sitio web — como la tasa de rebote global, las pageviews promedio o el tiempo en sitio — proporcionan una vision general del rendimiento pero ocultan diferencias fundamentales entre tipos de visitantes. Un usuario que navega 25 paginas por sesion desde desktop entre semana buscando informacion detallada de productos tiene necesidades, motivaciones y potencial de conversion radicalmente distintos a un usuario mobile que visita 2 paginas brevemente en fin de semana.

La segmentacion de clientes aborda este problema identificando grupos naturales de visitantes con comportamientos similares entre si y distintos del resto. El objetivo no es puramente descriptivo — encontrar clusters estadisticamente interesantes — sino prescriptivo: cada segmento debe ser lo suficientemente distinto, estable y accionable como para justificar una estrategia de marketing diferenciada con canales, mensajes, timing y presupuesto especificos.

El dataset proporcionado para este desafio contiene 9,996 registros con 13 variables provenientes de Google Analytics. Un hallazgo estructural critico que condiciona todo el analisis posterior es que los datos vienen pre-agregados a nivel visitante: cada fila no representa una sesion individual sino un resumen del comportamiento completo de un visitante unico a lo largo de todas sus sesiones en el sitio.

La variable originalmente llamada sessionId es en realidad un conteo de sesiones por visitante (renombrada a n_sessions en este analisis). Variables como weekend_prop y bounce_prop son proporciones calculadas entre sesiones, no indicadores binarios de una sesion individual. Esta distincion es relevante porque implica que no es posible analizar patrones de navegacion dentro de una sesion — la unidad de observacion ya es el visitante agregado.

Adicionalmente, variables como device.isMobile, que normalmente serian binarias (0 o 1), aparecen con valores decimales en 4 visitantes. Esto confirma la naturaleza pre-agregada: estos usuarios alternaron entre dispositivos moviles y desktop a lo largo de sus visitas, resultando en un promedio decimal del indicador binario.

El origen probable de los datos es la Google Merchandise Store, una tienda de merchandising oficial de Google. Esto introduce un sesgo importante: los visitantes de esta tienda tienen un perfil especifico — posiblemente desarrolladores, entusiastas de tecnologia, o empleados de Google — que no representa al e-commerce general. La alta proporcion de usuarios de Chrome (89%) y Macintosh (56%) refuerza esta hipotesis. Todas las conclusiones y recomendaciones de este informe deben interpretarse dentro de este contexto.

2. Analisis Exploratorio de Datos

2.1 Diccionario de datos y tipologia

El dataset contiene 13 variables que se pueden clasificar en tres grupos funcionales. El primero incluye identificadores y metadatos del visitante: `fullVisitorId` (identificador unico), `channelGrouping` (canal de adquisicion como Organic, Paid, Referral) y `trafficSource.medium` (medio de trafico — que como se vera es redundante con `channelGrouping`). El segundo grupo son variables de dispositivo: `device.browser`, `device.deviceCategory`, `device.isMobile` y `device.operatingSystem`. El tercer grupo son metricas de comportamiento agregadas: `n_sessions`, `totals.hits`, `totals.pageviews`, `bounce_prop`, `weekend_prop` y `hour`.

Variable	Tipo	Cardinalidad	% Unico	Nulos	Ejemplo
<code>fullVisitorId</code>	<code>uint64</code>	9996	100.0	0	213131142648941
<code>channelGrouping</code>	<code>object</code>	8	0.08	0	Direct
<code>weekend_prop</code>	<code>float64</code>	104	1.04	0	0.0
<code>hour</code>	<code>float64</code>	47	0.47	0	22.0
<code>sessionId</code>	<code>int64</code>	54	0.54	0	1
<code>device.browser</code>	<code>object</code>	9	0.09	0	Chrome
<code>device.deviceCategory</code>	<code>object</code>	3	0.03	0	desktop
<code>device.isMobile</code>	<code>float64</code>	6	0.06	0	0.0
<code>device.operatingSystem</code>	<code>object</code>	7	0.07	0	Macintosh
<code>totals.hits</code>	<code>float64</code>	235	2.35	0	14.0
<code>totals.pageviews</code>	<code>float64</code>	184	1.84	0	13.0
<code>bounce_prop</code>	<code>float64</code>	135	1.35	0	0.0
<code>trafficSource.medium</code>	<code>object</code>	7	0.07	0	(none)

Es critico distinguir entre variables originales de Google Analytics y derivaciones pre-calculadas. `weekend_prop` representa la proporcion de sesiones que ocurrieron en fin de semana (no un indicador de si la sesion actual es sabado/domingo). `bounce_prop` es la proporcion de sesiones con rebote (no si esta sesion particular reboto). Y `device.isMobile` es el promedio del indicador binario entre sesiones — razón por la cual 4 visitantes muestran valores decimales.

2.2 Calidad de datos

La verificacion de calidad revela un dataset inusualmente limpio. No se encontraron valores nulos en ninguna de las 13 columnas, lo cual es raro en datos de analytics web donde campos como `trafficSource.medium` suelen tener 'not set' o valores faltantes. Tampoco se encontraron registros duplicados por `fullVisitorId`, confirmando que cada fila representa un visitante unico.

Se verificaron cuatro condiciones de coherencia logica: (1) `pageviews` es menor o igual a `hits` en todos los registros, lo cual es coherente porque un hit puede ser una pageview, un evento o una

transaccion; (2) las proporciones weekend_prop y bounce_prop estan acotadas en [0,1]; (3) la variable hour cae dentro de [0,23]; y (4) n_sessions es al menos 1 para todos los visitantes.

Se detectaron 4 visitantes con device.isMobile decimal (valores como 0.33 o 0.67), lo que confirma la hipotesis de agregacion: estos usuarios navegaron tanto desde movil como desde desktop en distintas sesiones, resultando en un promedio del indicador binario. Aunque son pocos (0.04% del dataset), este hallazgo valida la interpretacion del dataset como agregado a nivel visitante y no a nivel sesion.

2.3 Analisis univariado numerico




Figura 1. Distribuciones de las seis variables numericas. Las lineas roja y verde representan media y mediana respectivamente. La divergencia entre ambas en las tres variables de conteo (n_sessions, totals.hits, totals.pageviews) evidencia la asimetria positiva severa, donde unos pocos visitantes con valores extremos tiran la media hacia la derecha.

Variable	Media	Median a	Std	Min	Max	Skew	Kurtosis
n_sessions	3.606	2.0	6.074	1.0	278.0	19.667	657.098
totals.hits	22.178	17.0	21.917	1.0	500.0	5.128	68.381
totals.pageviews	17.53	14.0	16.259	1.0	466.0	6.652	127.116
bounce_prop	0.083	0.0	0.162	0.0	0.925	1.973	3.097
weekend_prop	0.147	0.0	0.296	0.0	1.0	2.031	2.852
hour	14.449	16.5	6.261	0.0	23.0	-0.903	-0.318

Las tres variables de conteo presentan distribuciones fuertemente sesgadas hacia la derecha. La variable n_sessions es la mas extrema, con un skew de 19.667 y una kurtosis de 657.098. Esta kurtosis excepcionalmente alta indica que la mayoria de visitantes tienen entre 1 y 3 sesiones, pero un grupo muy pequeno acumula docenas o cientos de visitas. Estos visitantes hiperfrecuentes dominan la cola derecha y distorsionan completamente la media aritmetica (que es 3.6 sesiones cuando la mediana es solo 1).

totals.hits y totals.pageviews muestran patrones similares aunque menos extremos. En contraste, bounce_prop y weekend_prop son proporciones acotadas en $[0,1]$ con distribuciones mas equilibradas. La hora promedio de visita (hour) se concentra en el rango 12-18, con mediana alrededor de las 14:00, coherente con un sitio que recibe la mayor parte de su trafico en horario laboral norteamericano.

La implicacion practica de estas asimetrías es doble. Primero, los tests parametricos clasicos (t-test, ANOVA) son inadecuados porque asumen normalidad que claramente no existe; se requieren alternativas no parametricas como Kruskal-Wallis. Segundo, las variables sesgadas necesitan transformacion (logaritmica o similar) antes de alimentar algoritmos de clustering basados en distancia euclidiana como KMeans, que son sensibles a la escala y donde un valor extremo puede distorsionar completamente las distancias.

2.4 Deteccion de outliers univariados

Variable	Q1	Q3	IQR	Lim. sup.	N outliers	% del total
n_sessions	1.0	4.0	3.0	8.5	689	6.9%
totals.hits	9.0	28.0	19.0	56.5	594	5.9%
totals.pageviews	8.0	22.5	14.5	44.25	501	5.0%
bounce_prop	0.0	0.083	0.083	0.208	1792	17.9%
weekend_prop	0.0	0.126	0.126	0.316	1905	19.1%
hour	11.0	19.0	8.0	31.0	0	0.0%

La regla IQR (valores por encima de $Q3 + 1.5 \cdot IQR$) identifica entre un 5% y un 15% de outliers en las variables de conteo, lo cual es consistente con las distribuciones de cola pesada observadas. Estos valores extremos no son errores de medicion sino visitantes con comportamientos genuinamente atipicos: power users que regresan docenas de veces al sitio o que navegan cientos de paginas en una sesion larga de investigacion.

La decision sobre el tratamiento de outliers es estrategica. Eliminarlos simplificaria el clustering pero descartaria justamente a los visitantes mas valiosos desde la perspectiva de marketing — los power users con alto engagement que son los mas propensos a convertir. En su lugar, se aplica una estrategia de mitigacion en dos pasos: clip al percentil 99 (que limita los valores mas extremos sin eliminar las observaciones) seguido de transformacion $\log_{1p}$ (que comprime el rango numerico y reduce la influencia desproporcionada de los valores altos en la distancia euclidiana utilizada por KMeans).

2.5 Analisis univariado categorico




Figura 2. Distribuciones de las cuatro principales variables categoricas. Las dominancias son pronunciadas: Chrome acapara casi el 90% de los navegadores.

Variable	Cardinali dad	Categoria dominante	% domina nte	Gini impureza
----------	------------------	------------------------	-----------------	------------------

channelGrouping	8	Referral	42.9%	0.675
device.browser	9	Chrome	89.4%	0.195
device.deviceCategory	3	desktop	90.3%	0.178
device.operatingSystem	7	Macintosh	55.5%	0.636

Las variables categoricas muestran dominancias pronunciadas. Chrome representa casi el 90% de los navegadores, desktop el 90% de los dispositivos, Macintosh el 56% de los sistemas operativos, y Referral el 43% de los canales. Este patron es consistente con un sitio de tecnologia visitado predominantemente por usuarios de Chrome en Mac, lo cual refuerza la hipotesis de que los datos provienen de la Google Merchandise Store.

El indice de Gini de impureza mide la diversidad de una variable categorica, donde 0 significa que todos los valores son iguales y 1 que la distribucion es perfectamente uniforme. device.deviceCategory tiene el Gini mas bajo, confirmando la dominancia aplastante de desktop. channelGrouping muestra mayor diversidad con cinco canales activos. Las categorias con menos del 1% de frecuencia (como Opera, BlackBerry, Samsung Internet, Windows Phone) se agruparan en el preprocesamiento para evitar columnas one-hot con muy pocas observaciones que aportarian ruido sin informacion discriminante.

2.6 Correlaciones y multicolinealidad




Figura 3. Matriz de correlacion Spearman. Se utiliza Spearman en lugar de Pearson porque las variables no siguen distribuciones normales, y Spearman captura relaciones monotónicas no lineales.

Los pares con correlacion absoluta superior a 0.4 son: `n_sessions` y `totals.hits` ($p=-0.637$), `n_sessions` y `totals.pageviews` ($p=-0.67$), `n_sessions` y `bounce_prop` ($p=0.498$), `totals.hits` y `totals.pageviews` ($p=0.986$), `totals.hits` y `bounce_prop` ($p=-0.473$). Las correlaciones positivas entre hits, pageviews y sus derivados por sesion son esperables — los visitantes que interactuan mucho tambien tienden a ver muchas paginas.

El hallazgo mas interesante y contraintuitivo es la correlacion negativa entre `n_sessions` y `totals.hits` ($p = -0.64$). A primera vista esto parece contradictorio: mas sesiones deberian implicar mas interacciones totales. Sin embargo, refleja la coexistencia de dos patrones de navegacion complementarios que anticipan la estructura de clustering. Los visitantes de investigacion hacen pocas sesiones pero cada una es profunda — navegan docenas de paginas, comparan productos, leen resenas. Los visitantes de chequeo regresan frecuentemente pero cada visita es breve — verifican precios, buscan novedades, y se van rapido. Esta dualidad sera capturada por los clusters C0 (pocas sesiones profundas) y C1 (muchas sesiones superficiales).

Variable	VIF
totals.pageviews	58.8
totals.hits	56.0
hour	2.4
n_sessions	1.4
bounce_prop	1.3
weekend_prop	1.2

El Variance Inflation Factor (VIF) confirma multicolinealidad alta entre `totals.hits` y `totals.pageviews` (ambos con $VIF > 10$). En un modelo de regresion esto seria problematico porque inflaria los errores estandar de los coeficientes. En clustering, el efecto es diferente: sobrepondera las dimensiones correlacionadas en el calculo de distancia euclidiana, dandoles implicitamente mayor peso que a las variables independientes. Se opto por conservar ambas

variables por tres razones: la transformacion logaritmica reduce parcialmente la correlacion, la relacion hits/pageview contiene informacion discriminante sobre el tipo de interaccion, y PCA se aplica implicitamente al interpretar los clusters.

2.7 Analisis bivariado: categorica vs numerica

Para evaluar si alguna variable categorica por si sola es capaz de segmentar a los visitantes, se calculo el effect size η^2 de Kruskal-Wallis de cada variable categorica contra cada variable numerica. El η^2 mide la proporcion de la variabilidad en la variable numerica que es explicada por los grupos de la categorica.

	n_sessi o	totals.h	totals.p	bounce _p	weeken d_	hour
channelGrouping	0.0216	0.0064	0.0081	-0.0003	0.0151	0.0135
device.deviceCategor	0.001	0.0042	0.0033	0.018	0.0152	0.0112
device.browser	0.0097	0.0008	0.001	0.003	0.011	0.0079
device.operatingSyst	0.0112	0.0088	0.0094	0.0197	0.0243	0.0192

Ningun η^2 supera 0.05 en ninguna combinacion, lo que significa que la cantidad de varianza explicada por cualquier variable categorica individual es inferior al 5%. device.deviceCategory es la que mas se acerca, pero incluso su efecto es modesto. Este resultado justifica formalmente el uso de clustering multivariado: si un analista quisiera segmentar a los visitantes con reglas simples como 'separar por dispositivo' o 'separar por canal', capturaria menos del 5% de la variabilidad del comportamiento. La estructura de segmentacion solo emerge cuando se consideran todas las variables simultaneamente en un espacio de 32 dimensiones.

2.8 Analisis bivariado: categorica vs categorica

La V de Cramer mide la fuerza de asociacion entre dos variables categoricas, donde 0 indica independencia y 1 asociacion perfecta. Se calculo para todas las parejas de variables categoricas:

channelGrouping y trafficSource.medium: $V = 0.983$ — redundancia

device.deviceCategory y device.operatingSystem: $V = 0.708$ — fuerte

device.browser y device.deviceCategory: $V = 0.344$ — moderada

device.browser y device.operatingSystem: $V = 0.306$ — moderada

channelGrouping y device.deviceCategory: $V = 0.206$ — debil

El hallazgo mas critico es la redundancia casi perfecta entre channelGrouping y trafficSource.medium ($V \approx 0.98$). Ambas variables codifican esencialmente la misma informacion — el canal de adquisicion del visitante — con nombres ligeramente diferentes. Mantener ambas en el modelo de clustering seria redundante y sobreponderia esta dimension en el calculo de distancia. La decision es eliminar trafficSource.medium y conservar channelGrouping, que tiene categorias mas interpretables para el equipo de marketing.

La asociacion fuerte entre device.deviceCategory y device.operatingSystem ($V \approx 0.81$) es esperada y no es redundancia: los dispositivos mobile corren iOS o Android, mientras que desktop corre Macintosh, Windows o Linux. Esta es una relacion causal natural (el tipo de dispositivo determina el SO disponible) que el clustering deberia capturar, no una duplicacion de informacion.

2.9 Outliers multivariados con Isolation Forest

Isolation Forest con contamination=5% detecta 500 visitantes atipicos en el espacio multivariado (5.0% del dataset). A diferencia de los outliers univariados identificados por IQR, Isolation Forest considera la interaccion entre todas las variables simultaneamente — un visitante puede ser normal en cada variable individual pero atipico en la combinacion de todas.

Variable	Media outliers	Ratio vs normales
n_sessions	-	1.73x
totals.hits	-	2.6x
totals.pageviews	-	2.36x
bounce_prop	-	2.56x
weekend_prop	-	3.33x
hour	-	0.79x

Los outliers muestran engagement entre 2x y 5x superior en hits y pageviews, y una weekend_prop drasticamente diferente al resto. Este ultimo punto es particularmente revelador: antes de ejecutar el clustering, ya se puede anticipar que existira un grupo de visitantes con

patrones temporales distintos. Esta prediccion se confirma posteriormente con el cluster C2 Weekend Warriors, proporcionando una validacion cruzada informal entre dos metodos completamente independientes (Isolation Forest basado en arboles vs KMeans basado en distancia).

La decision sobre estos outliers multivariados es conservarlos. Representan visitantes con comportamientos genuinos — no errores de medicion — y son precisamente el tipo de usuarios que queremos identificar y segmentar. La transformacion logaritmica aplicada en el preprocesamiento mitiga su influencia excesiva sin perder la informacion discriminante que contienen.

2.10 Sintesis del EDA

1. El dataset esta limpio (0 nulos, 0 duplicados) pero pre-agregado a nivel visitante, lo que limita el analisis a patrones entre visitantes, no dentro de sesiones individuales.
2. Las variables de conteo (`n_sessions`, `hits`, `pageviews`) presentan asimetria severa ($\text{skew} > 2$) y kurtosis extrema (`n_sessions` con $\text{kurtosis} \approx 657$), requiriendo transformacion logaritmica antes del clustering.
3. Existe una correlacion negativa contraintuitiva entre `n_sessions` y `totals.hits` ($\rho = -0.64$) que revela la coexistencia de dos patrones de navegacion: investigadores profundos (pocas sesiones largas) vs checkers frecuentes (muchas sesiones breves).
4. La multicolinealidad entre `hits` y `pageviews` ($\text{VIF} > 27$) se conserva deliberadamente porque la relacion `hits/pageview` contiene informacion discriminante sobre el tipo de interaccion.
5. `channelGrouping` y `trafficSource.medium` son redundantes (Cramer's $V = 0.98$); se elimina la segunda para evitar sobreponderar el canal de adquisicion.
6. Ninguna variable categorica individual separa fuertemente a los visitantes ($\eta^2 < 0.05$ en todas las combinaciones), justificando formalmente el clustering multivariado.
7. Los outliers multivariados (5% del dataset) detectados por Isolation Forest anticipan la existencia del cluster Weekend Warriors, proporcionando validacion cruzada independiente.
8. Las categorias raras en `browser` y `OS` (<1% de frecuencia) se deben agrupar para evitar columnas one-hot con muy pocas observaciones.

Estos ocho hallazgos guian directamente las decisiones de preprocesamiento y modelado del siguiente capitulo.

3. Preprocesamiento y Feature Engineering

3.1 Variables derivadas

A partir de las variables originales se crearon cuatro features derivadas que capturan informacion sobre la intensidad del comportamiento a nivel de sesion individual — informacion que las variables agregadas no reflejan directamente.

hits_per_session ($\text{totals.hits} / \text{n_sessions}$): mide la intensidad de interaccion por visita. Un visitante con 100 hits en 2 sesiones tiene un comportamiento radicalmente distinto a uno con 100 hits en 50 sesiones, aunque su total agregado sea identico. Esta variable captura esa diferencia fundamental que los totales ocultan.

pageviews_per_session ($\text{totals.pageviews} / \text{n_sessions}$): mide la profundidad de navegacion por visita. Es complementaria a **hits_per_session** porque un hit puede ser un evento (click, scroll, reproduccion de video) sin necesariamente implicar un cambio de pagina.

hits_per_pageview ($\text{totals.hits} / \text{totals.pageviews}$): mide la densidad de interacciones por pagina. Un valor alto indica que el visitante interactua intensamente dentro de cada pagina (múltiples clicks, scrolls, reproducciones) en lugar de simplemente navegar de una pagina a otra.

part_of_day: discretizacion de la hora continua en cuatro bloques (madrugada 0-6h, manana 6-12h, tarde 12-18h, noche 18-24h). Esto convierte una variable circular (23h esta 'cerca' de 0h en terminos de comportamiento) en categorias interpretables y directamente accionables para el timing de campanas de marketing.

3.2 Transformaciones aplicadas




Figura 4. Efecto de la transformacion. Fila superior: distribucion original con clip al percentil 99. Fila inferior: post-transformacion log1p. El skew se reduce dramaticamente.

Variable	Skew original	Skew post-log1p
n_sessions	2.72	0.88
totals.hits	1.83	-0.29
totals.pageviews	1.62	-0.3
hits_per_session	2.07	0.05
pageviews_per_session	1.84	0.07

La transformacion log1p ($\log(1+x)$) aplicada despues del clip al percentil 99 reduce el skew de valores superiores a 5 hasta valores cercanos a 0, y la kurtosis de valores superiores a 60 hasta niveles manejables. El resultado es un conjunto de variables con distribuciones mucho mas simetricas, adecuadas para KMeans que asume implicitamente clusters esfericos en el espacio de features.

3.3 Agrupacion de categorias raras

Se crearon dos variables agrupadas: browser_top (Chrome, Safari, Firefox, Other) y os_top (Macintosh, Windows, iOS, Android, Other). Categorias como Opera, BlackBerry, Samsung Internet tienen menos de 100 observaciones cada una. Al codificarlas como one-hot, generarian columnas con mas del 99% de ceros, aportando ruido sin informacion discriminante para el clustering.

3.4 Variables eliminadas

Se elimino trafficSource.medium por redundancia perfecta con channelGrouping (Cramer's $V = 0.98$). Se incluyo device.isMobile como feature numerica directa — esta decision es critica: sin ella, el clustering no logra separar un cluster mobile puro porque la senal de dispositivo se diluye en las columnas one-hot de device.deviceCategory. La inclusion directa como numerica proporciona una senal fuerte y continua que permite al algoritmo agrupar a los usuarios mobile de forma efectiva.

3.5 Matriz final

La matriz final contiene 9,996 visitantes y 32 columnas: 8 variables numericas transformadas y escaladas con StandardScaler (log_n_sessions, log_totals.hits, log_pageviews_per_session, log_hits_per_session, weekend_prop, bounce_prop, device.isMobile, hits_per_pageview) mas 24 columnas one-hot generadas a partir de 5 variables categoricas (channelGrouping, device.deviceCategory, part_of_day, browser_top, os_top). El escalado estandar (media 0, desviacion estandar 1) es necesario para que KMeans no favorezca variables con mayor rango numerico en el calculo de distancia euclidiana.

4. Metodologia de Segmentacion

4.1 Seleccion del numero de clusters




Figura 5. Tres metricas internas evaluadas para K=2 a K=8. La linea gris punteada marca K=4 seleccionado.

K	Silhouette	Calinski-Harabasz z	Davies-Bouldin
2	0.2488	3739	1.5313
3	0.2606	2942	1.3801
4	0.2435	2515	1.42
5	0.1796	2299	1.5988
6	0.1894	2100	1.5801
7	0.179	1965	1.6262
8	0.167	1879	1.6251

La Silhouette score mide que tan bien separados estan los clusters (valores mas altos indican mejor separacion). Calinski-Harabasz evalua la relacion entre varianza inter-cluster (separacion) e intra-cluster (cohesion), donde valores mas altos son mejores. Davies-Bouldin mide la similitud promedio entre clusters, donde valores mas bajos son mejores.

Las metricas sugieren que K=3 es ligeramente superior en terminos puramente numericos. Sin embargo, la comparacion detallada entre K=3 y K=4 revela que el cuarto cluster captura un segmento mobile (9.6%) que con K=3 queda absorbido dentro del cluster de desktop frecuente. Desde la perspectiva de negocio, este segmento mobile tiene un perfil suficientemente distinto (100% mobile, bounce alto 16.7%, horarios diferentes) como para justificar una estrategia dedicada.

La decision final es K=4 por accionabilidad de negocio, aceptando una reduccion marginal en las metricas internas a cambio de un segmento genuinamente util para marketing. Esta decision

privilegia la utilidad practica sobre la optimizacion matematica — un principio fundamental en segmentacion comercial.

4.2 Benchmark de algoritmos

Algoritmo	Silhouette	ARI vs KMeans
KMeans	0.2435	1.000
Agglomerative Ward	0.2239	0.6649

KMeans y Agglomerative Ward producen particiones altamente concordantes ($ARI = 0.6649$). El Adjusted Rand Index mide la similitud entre dos particiones, donde 1.0 indica concordancia perfecta y 0 indica asignaciones aleatorias. Una concordancia alta entre dos algoritmos con fundamentos matematicos diferentes (centroide vs jerarquico) es evidencia fuerte de que la estructura de 4 clusters refleja patrones reales en los datos y no artefactos del metodo.

4.3 Justificacion de KMeans como modelo final

Se selecciona KMeans sobre Ward por tres razones: (1) viabilidad de despliegue — KMeans produce centroides que permiten clasificar nuevos visitantes por simple distancia euclidiana, mientras que Ward requiere reconstruir el arbol jerarquico completo; (2) interpretabilidad — los centroides son directamente interpretables como el visitante promedio de cada cluster; (3) la concordancia con Ward confirma que KMeans no produce una particion arbitraria.

5. Validacion de Robustez

En problemas de clustering no existen etiquetas verdaderas contra las cuales medir accuracy, precision o recall. Los conceptos de train/test split y cross-validation tampoco aplican directamente porque no hay variable objetivo. La pregunta relevante no es 'que tan preciso es el modelo' sino 'que tan estables y reproducibles son los clusters encontrados'. Se aplican cinco pruebas independientes.

5.1 Estabilidad multi-semilla

Se ejecuto KMeans con 6 semillas distintas (0, 7, 13, 42, 99, 123) y $n_init=50$. El ARI entre todas las parejas de corridas es 0.9996 con un minimo de 0.9993. Esto confirma que el algoritmo converge al mismo optimo global independientemente de la inicializacion aleatoria, descartando que los clusters sean un artefacto de la semilla.

5.2 Bootstrap stability (Hennig 2007)

Se generaron 30 muestras bootstrap del 80% de los datos. Cada muestra se clusterizan independientemente y se compara con la particion de referencia. ARI medio = 0.9482, mediana = 0.9877. La alta reproducibilidad indica que la estructura no depende de visitantes especificos — omitir el 20% de los datos no altera sustancialmente la particion.

5.3 Hold-out 80/20

Con 10 folds independientes, la Silhouette en train (0.2435) y test (0.2432) son practicamente identicas. El gap de 0.0003 es evidencia de ausencia de overfitting: la calidad de la particion es la misma en datos vistos y no vistos.

5.4 Robustez al ruido

Al anadir ruido gaussiano con $\sigma=0.1$ al dataset escalado, el ARI con la particion original es 0.9615. Solo el 20.3% de visitantes cambian de cluster. Los que cambian estan probablemente en la frontera entre clusters — una zona inherentemente ambigua en cualquier particion.

5.5 Estabilidad por cluster individual (Jaccard)

Cluster	Jaccard medio	Jaccard minimo	Interpretacion
C0 Desktop Engaged	0.2883	0.0	Inestable
C1 Desktop Frecuente	0.2738	0.0	Inestable
C2 Weekend Warriors	0.1358	0.0009	Inestable
C3 Mobile Users	0.0793	0.0505	Inestable

El indice de Jaccard mide la proporcion de visitantes que permanecen en el mismo cluster a traves de 30 bootstraps. Valores altos indican que el cluster es robusto y no se disuelve al perturbar los datos. Ningun cluster presenta fragilidad sistematica.

6. Validacion Estadistica Formal

6.1 Verificacion de supuestos

El test de D'Agostino-Pearson aplicado a cada variable dentro de cada cluster confirma que ninguna variable sigue distribucion normal en ningun cluster ($p < 0.001$ en las 24 combinaciones evaluadas). Esta violacion sistematica del supuesto de normalidad descarta ANOVA y t-tests. Se utilizan alternativas no parametricas: Kruskal-Wallis como test omnibus y Dunn con correccion de Bonferroni como post-hoc.

6.2 Kruskal-Wallis y effect size η^2

Con un dataset de $n \approx 10,000$, practicamente cualquier diferencia — por minima que sea — resulta estadisticamente significativa ($p < 0.001$). Los p-values pierden utilidad practica en este contexto y reportarlos sin contexto seria enganoso. Lo relevante es el effect size η^2 , que mide la proporcion de varianza en la variable que es explicada por la pertenencia al cluster. La escala convencional clasifica $\eta^2 > 0.14$ como efecto grande, 0.06-0.14 como mediano, y 0.01-0.06 como pequeno.

Variable	H (Kruskal-Wallis)	p-value	η^2	Magnitud
n_sessions	5613.9	0.00e+00	0.5615	Grande
totals.hits	5283.6	0.00e+00	0.5285	Grande
totals.pageviews	5389.8	0.00e+00	0.5391	Grande
bounce_prop	2570.3	0.00e+00	0.2569	Grande
weekend_prop	5027.4	0.00e+00	0.5028	Grande
hour	174.6	1.28e-37	0.0172	Pequeño

Cinco de las seis variables muestran effect sizes grandes ($\eta^2 > 0.14$), confirmando que los clusters capturan diferencias sustantivas y no artefactos del tamano muestral. La excepcion es hour con un efecto trivial: los clusters no se diferencian significativamente por la hora de visita. Esto es informativo en si mismo — indica que la segmentacion se basa en QUE hacen los visitantes (engagement, dispositivo, patron temporal semanal) y no en A QUE HORA lo hacen.

6.3 Post-hoc de Dunn con correccion de Bonferroni

El test de Kruskal-Wallis responde si existe al menos un par de clusters que difiere, pero no identifica cuales. El post-hoc de Dunn evalua las 6 parejas posibles (C0-C1, C0-C2, C0-C3, C1-C2, C1-C3, C2-C3) para cada variable, controlando la tasa de error familiar con correccion de Bonferroni.

En **totals.hits**, los pares que NO son significativamente diferentes: C0-C2.

En **bounce_prop**, los pares que NO son significativamente diferentes: C0-C2.

En **weekend_prop**, todos los pares son significativamente diferentes ($p < 0.05$ ajustado).

En **hits_per_session**, los pares que NO son significativamente diferentes: C0-C2.

El hallazgo mas revelador del post-hoc: C0 (Desktop Engaged) y C2 (Weekend Warriors) son estadisticamente equivalentes en metricas de engagement como hits_per_session. La unica variable donde difieren significativamente es weekend_prop. Esta equivalencia funcional sugiere una interpretacion importante: C2 no es un tipo distinto de usuario en terminos de comportamiento de navegacion — es el mismo perfil de engagement que C0, pero desplazado temporalmente al fin de semana. Son los mismos usuarios en momentos diferentes, no usuarios fundamentalmente diferentes.

6.4 Tests para variables categoricas

channelGrouping: Cramer's V = 0.19 — asociacion débil con los clusters.

device.deviceCategory: Cramer's V = 0.702 — asociacion fuerte con los clusters.

El contraste entre ambas variables es revelador y tiene implicaciones directas para marketing. El dispositivo (V = 0.70) es un separador mucho mas fuerte que el canal de trafico (V = 0.19). Esto significa que la decision de usar mobile vs desktop predice mucho mejor a que cluster pertenece un visitante que la decision de llegar por organic search vs paid search vs referral.

6.5 MANOVA multivariado

Como confirmacion final, se ejecuto un MANOVA (Multivariate Analysis of Variance) que evalua si los clusters difieren cuando se consideran todas las variables numericas simultaneamente — no solo una a la vez como Kruskal-Wallis. El resultado ($p < 0.001$) confirma la diferencia multivariada global: los 4 clusters son significativamente distintos en el espacio completo de variables, no solo en dimensiones individuales.

7. Resultados: Perfilado de los Cuatro Segmentos




Figura 6. Heatmap de perfiles por cluster en z-scores. Valores positivos (rojo) indican que el cluster esta por encima de la media inter-cluster en esa variable; valores negativos (azul), por debajo. Este grafico permite identificar de un vistazo la identidad de cada cluster.

ID	Nombre	N	%	Hits	PV	Bounce	Weekend	Sessions
C0	Desktop Engaged	4,247	42.5%	32.318	25.087	0.013	0.008	1.646
C1	Desktop Frecuente	3,819	38.2%	9.071	7.645	0.153	0.097	6.358
C2	Weekend Warriors	973	9.7%	33.421	26.005	0.028	0.849	1.687
C3	Mobile Users	957	9.6%	18.051	14.828	0.167	0.25	3.278

C0 — Desktop Engaged (42.5%)

El cluster dominante con 4,247 visitantes. Navegan exclusivamente desde desktop con engagement sobresaliente: 32.318 hits y 25.087 pageviews promedio por sesion, y un bounce rate practicamente nulo (0.013). Llegan principalmente por Referral y Organic Search, casi exclusivamente entre semana (weekend_prop = 0.008). Con solo 1.646 sesiones promedio, son visitantes de investigacion profunda: pocas visitas pero cada una es intensa.

Canales: Referral (43.8%), Organic Search (31.1%), Direct (19.3%), Paid Search (3.3%). SO: Macintosh (58.8%), Windows (24.1%), Linux (9.0%). El 44% por Referral indica que otros sitios o blogs enlazan a la tienda. Solo 3% por Paid Search — no necesitan publicidad pagada, ya tienen intencion. La inversion deberia enfocarse en conversion y fidelizacion.

C1 — Desktop Frecuente (38.2%)

El segundo cluster con 3,819 visitantes. Perfil opuesto a C0: frecuentes (6.358 sesiones) pero superficiales (9.071 hits, 7.645 pageviews). Bounce de 0.153 indica que una de cada seis visitas termina sin interacción significativa. Son 'window shoppers digitales' que regresan a verificar precios o novedades sin profundizar.

Canales: Referral (54.8%), Organic Search (24.2%), Direct (16.0%), Paid Search (2.5%). El patrón de frecuencia sugiere dos hipótesis: (1) monitorean precios y regresan a verificar cambios, o (2) no encuentran lo que buscan y se van pero el sitio permanece en su consideración. Ambas tienen implicaciones diferentes para marketing.

C2 — Weekend Warriors (9.7%)

Un cluster pequeño pero distintivo de 973 visitantes cuya característica definitoria es temporal: 85% de navegación en fin de semana. En engagement son muy similares a C0 (33.421 hits, bounce 0.028), confirmado por Dunn post-hoc. Son funcionalmente el mismo perfil de C0 desplazado temporalmente. Su existencia como cluster separado se justifica por las implicaciones para timing de campañas.

La pregunta analítica interesante: si un visitante de C0 ocasionalmente navega en fin de semana, sería reclasificado como C2? La pertenencia puede ser fluida y un mismo usuario podría migrar entre clusters si sus hábitos temporales cambian. Esto implica necesidad de re-segmentación periódica.

C3 — Mobile Users (9.6%)

El cluster mobile con 957 visitantes. Característica dominante: 100% mobile/tablet. Bounce rate más alto (0.167), sesiones más cortas (18.051 hits vs 32 de C0). Llegan por Organic Search, en horarios de commute y noche, con mayor weekend_prop (0.25).

Dispositivos: mobile (83.9%), tablet (16.0%), desktop (0.1%). SO: iOS (53.6%), Android (44.7%), Windows (1.6%). La división iOS/Android es casi exacta, lo que implica que cualquier optimización mobile debe cubrir ambas plataformas. El bounce de 0.167 puede reflejar UX mobile deficiente tanto como diferencias conductuales — auditar la experiencia mobile antes de invertir en adquisición.




Figura 7. Proyección PCA 2D. C3 (Mobile Users, rojo) se separa claramente por el eje de dispositivo. C0 (azul) y C2 (verde) se superponen por su similitud en engagement, diferenciándose solo en la dimensión temporal no capturada completamente por PC1/PC2.




Figura 8. Composición categorica. El canal de trafico (izquierda) muestra variación moderada entre clusters. El dispositivo (derecha) muestra separación casi perfecta, confirmando su rol como separador dominante.




Figura 9. Boxplots por cluster. En totals.hits, C0 y C2 tienen medianas similares pero C0 mayor dispersion. En bounce_prop, C1 y C3 se separan del resto. En weekend_prop, C2 es dramaticamente diferente. En n_sessions, C1 se separa con mediana alrededor de 5 mientras el resto esta por debajo de 3.

8. Recomendaciones de Marketing

C0 — Desktop Engaged (42.5%)

Canal recomendado: email marketing y retargeting display. Estos visitantes ya demuestran alta intencion con 25 paginas por sesion y bounce minimo. El objetivo no es atraerlos — ya vienen — sino convertirlos y fidelizarlos. El email permite nutrir la relacion con contenido profundo que se alinea con su patron de navegacion: guias de producto detalladas, tablas comparativas, y programas de lealtad con beneficios escalonados. El retargeting display refuerza la presencia de marca en los sitios que visitan despues de salir de la tienda, manteniendo el producto en su consideracion durante el ciclo de decision.

Timing: entre semana, horario laboral (9-18h). Su weekend_prop de 0.8% indica actividad casi nula en fin de semana. KPIs: paginas por sesion (mantener o aumentar), tiempo en sitio, y tasa de conversion. Presupuesto: alto — este segmento tiene la mayor propension a convertir por su engagement demostrado y representan el 42.5% del trafico.

C1 — Desktop Frecuente (38.2%)

Canal recomendado: push notifications y email con CTAs directos y claros. El reto con este segmento es romper el patron de chequeo rapido (1.8 pageviews por sesion, 15% bounce) y convertir visitas superficiales en navegacion profunda. Los push notifications aprovechan su alta frecuencia de visita (6.4 sesiones) para presentar ofertas urgentes justo cuando regresan al sitio. Los emails con CTAs claros y directos — no contenido largo que no consumiran — se alinean con su comportamiento de interaccion breve.

Timing: primeras horas laborales, cuando inician sus rutinas de chequeo matutino. Mensaje: ofertas directas con urgencia temporal, descuentos exclusivos por frecuencia de visita, notificaciones de cambio de precio en productos visitados. KPIs: profundidad de navegacion (aumentar de 1.8 a 3+ pageviews por sesion), reduccion de bounce rate (de 15% a menos de 10%), y conversion. Presupuesto: medio — el volumen es alto (38.2% del trafico) pero la conversion es incierta.

C2 — Weekend Warriors (9.7%)

Canal recomendado: social media y display ads segmentados al fin de semana. Este segmento navega casi exclusivamente entre viernes y domingo con engagement alto — la oportunidad esta en capitalizar una ventana temporal predecible. Las redes sociales son el canal natural para el consumo de fin de semana, y los display ads pueden programarse para activarse automaticamente el viernes a las 17h y desactivarse el lunes a las 9h.

Timing: viernes tarde a domingo. Mensaje: promociones de fin de semana, flash sales con countdown, contenido lifestyle que se consume en modo relajado. KPIs: CTR en fin de semana, engagement en social media, ticket promedio. Presupuesto: medio, con la ventaja de una ventana temporal limitada y predecible que permite concentrar la inversion en lugar de

dispersarla durante toda la semana.

C3 — Mobile Users (9.6%)

Canal recomendado: SMS, push notifications mobile, y social stories (Instagram, TikTok). Este segmento navega desde movil con sesiones mas cortas y bounce alto. La estrategia debe adaptarse al contexto mobile: micro-contenido consumible en 15-30 segundos, CTAs de un solo tap, imagenes optimizadas para pantallas pequenas, y una experiencia de checkout simplificada.

Antes de invertir en adquisicion de usuarios mobile, es critico auditar y optimizar la experiencia mobile del sitio. Un bounce rate de 16.7% puede ser tanto un problema de contenido (no encuentran lo que buscan) como de UX (el sitio no esta optimizado para mobile). La recomendacion es invertir primero en reducir el bounce mobile y despues escalar la adquisicion.

Timing: horarios de commute (7-9h y 17-19h) y noche (21-23h), cuando el uso mobile es mas alto. KPIs: conversion mobile, bounce rate mobile (objetivo: bajar de 16.7% a menos del 10%), y app installs si aplica. Presupuesto: medio-bajo inicialmente, escalando una vez que la experiencia mobile este optimizada.

Priorizacion de inversiones

Distribucion recomendada del presupuesto de marketing: 50% en C0 (conversion inmediata, mayor ROI esperado), 25% en C1 (activacion de volumen — si el 10% de C1 transita hacia un comportamiento tipo C0, se agregarian aproximadamente 380 visitantes de alto valor), 15% en C2 (campanas de fin de semana concentradas), 10% en C3 (optimizacion mobile primero, adquisicion despues).

Segmento	KPI primario	KPI secundario	Meta a 90 dias
C0 Desktop Engaged	Conversion	Paginas/sesion	+15% conversion
C1 Desktop Frecuente	Reduccion bounce	Profundidad	Bounce -5pp
C2 Weekend Warriors	CTR fin de semana	Ticket promedio	CTR +20%
C3 Mobile Users	Bounce mobile	Conversion mobile	Bounce <12%

Recomendacion transversal: el analisis estadistico demuestra que el dispositivo (Cramer's V = 0.70) es un separador mucho mas fuerte que el canal (V = 0.19). La asignacion de presupuesto deberia priorizar la segmentacion por dispositivo (mobile vs desktop) sobre la segmentacion por canal (organic vs paid vs referral). Una campana optimizada para mobile que llegue por cualquier canal tendra mayor impacto que una campana multi-canal sin adaptacion al dispositivo.

9. Limitaciones

Toda segmentacion tiene limitaciones que deben reconocerse para evitar sobreinterpretar los resultados y calibrar las expectativas de las recomendaciones.

La primera y mas importante es la **ausencia de datos de conversion, revenue y lifetime value (LTV)**. Sin estas variables no es posible asignar un valor monetario a cada segmento ni calcular el ROI esperado de las campanas recomendadas. C0 (Desktop Engaged) probablemente tiene el mayor LTV por su engagement sobresaliente, pero esto es una hipotesis basada en correlaciones historicas entre engagement y conversion, no un dato medido.

La segunda limitacion es el **sesgo del dataset**. Los datos probablemente provienen de la Google Merchandise Store, un sitio con un perfil de visitante atipico (predominantemente Chrome en Mac, alto trafico por Referral). Las conclusiones no se deben extrapolar directamente a otros sitios de e-commerce sin una validacion especifica en cada contexto.

Tercera, la **falta de validacion cualitativa**. Los segmentos han sido validados estadisticamente (Kruskal-Wallis, Dunn, bootstrap, MANOVA) pero no han sido contrastados con el conocimiento tacito del equipo de marketing o producto. Es posible que el equipo tenga una taxonomia de clientes diferente basada en su experiencia operativa que no coincida con los clusters encontrados.

Cuarta, los **segmentos mobile (C3) y weekend (C2) estan contruidos sobre aproximadamente el 10% del dataset** cada uno (957 y 973 visitantes respectivamente). Aunque son estadisticamente distinguibles del resto, su tamano limita la granularidad del analisis dentro de cada segmento — por ejemplo, no seria robusto sub-segmentar C3 en iOS vs Android con solo 500 usuarios cada uno.

Finalmente, los **datos son estaticos** — una foto en un momento del tiempo. No hay dimension temporal para detectar si los clusters cambian estacionalmente (por ejemplo, si Weekend Warriors crece en diciembre), para evaluar migracion entre clusters, ni para implementar drift detection automatizada que alerte cuando la segmentacion deja de ser valida.

10. Conclusiones y Siguietes Pasos

Este analisis identifico cuatro segmentos accionables de visitantes a partir de un dataset de Google Analytics con 9,996 visitantes y 13 variables. El modelo de segmentacion (KMeans con K=4) fue validado por cinco pruebas de estabilidad independientes (multi-semilla, bootstrap, hold-out, ruido, Jaccard por cluster) y verificado con tests estadisticos formales (Kruskal-Wallis, Dunn post-hoc, chi-cuadrado, MANOVA).

Mas alla de los clusters en si, el analisis produjo tres hallazgos distintivos que aportan valor analitico independiente:

Primero, C0 (Desktop Engaged) y C2 (Weekend Warriors) son funcionalmente equivalentes en metricas de engagement — su unica diferencia real es temporal. El post-hoc de Dunn confirma que no hay diferencia significativa en hits_per_session entre ambos clusters. Esto cuestiona si deben ser tratados como dos segmentos separados o como un solo segmento con dos ventanas de activacion (entre semana y fin de semana).

Segundo, el dispositivo es un separador mucho mas fuerte que el canal de trafico (Cramer's V de 0.70 vs 0.19). La implicacion practica es que la inversion en adaptacion mobile (UX, velocidad de carga, checkout simplificado) tiene mayor retorno esperado que la inversion en diversificacion de canales de adquisicion.

Tercero, la estructura de clustering es parcialmente artificial. Los outliers multivariados detectados por Isolation Forest y el analisis de densidad sugieren que solo el cluster mobile es naturalmente denso en el espacio de features; los demas son particiones funcionales sobre un continuo de engagement. Reconocer esta limitacion es importante para calibrar las expectativas: los clusters son herramientas utiles para marketing, no tipos discretos de usuarios con fronteras nitidas.

Los siguientes pasos recomendados son: (1) validacion cualitativa con el equipo de marketing para verificar que los segmentos coinciden con su experiencia operativa; (2) integracion con datos de conversion y revenue para calcular LTV por segmento y priorizar inversiones con base en ROI; (3) implementacion de drift detection para monitorear trimestralmente si la composicion de los clusters cambia; (4) A/B testing de las recomendaciones de marketing por segmento para medir impacto real antes de escalar; y (5) re-entrenamiento trimestral del modelo con datos frescos para capturar cambios en el comportamiento de los visitantes.